

Analisi dell'Impatto Turistico dell'America's Cup 2026 a Cagliari

Autore: Matteo Cambarau

Corso: Web Analytics e Analisi Testuale — DSBAI, Università degli Studi di Cagliari

Anno accademico: 2025/2026

Supervisore: Prof. Marco Ortu

Executive Summary

Questo report misura l'impatto dell'America's Cup 2026 sulla soddisfazione dei turisti a Cagliari, analizzando **15.509 recensioni Booking.com** (Cagliari e Olbia come città di controllo, 2025-2026) tramite sentiment analysis e topic modeling.

Risultati chiave:

Indicatore	Risultato
Afflusso turistico durante l'evento	Recensioni +81% rispetto allo stesso periodo 2025 (333 vs 184)
Rating Cagliari durante l'evento	Scende da 9.20 (pre) a 8.65 (during), con maggiore variabilità
Sentiment durante l'evento	Da +0.79 (baseline 2025) a +0.56 (2026): calo del -29%
Recupero post-evento	Sentiment Cagliari sale a +0.76 nel post-evento, valore superiore al pre (+0.70) e al baseline 2025 (+0.67)
Confronto con Olbia (controllo)	Olbia non mostra lo stesso calo durante l'evento — segnale specifico di Cagliari
Temi ricorrenti	Posizione, pulizia, colazione e personale dominano in tutte le finestre; durante l'evento emergono critiche su rumore e traffico
Scelta del modello di sentiment (confronto su gold standard, 150 rec.)	Confrontati Feel-IT (58% accuracy) e nlptown (96% accuracy) — scelto nlptown come modello finale. Il 96% è in parte un artefatto: entrambi i modelli faticano a riconoscere le recensioni negative, che sono rarissime nel dataset

In sintesi: l'America's Cup ha generato un aumento volumetrico significativo degli arrivi turistici ma, nel breve periodo dell'evento, un calo percepito della soddisfazione — sentiment da +0.79 (baseline 2025) a +0.56 (2026 during), -29% — verosimilmente legato a sovraffollamento, rumore e traffico. Il periodo post-evento registra invece il valore di sentiment più alto del 2026 per Cagliari (+0.76), superiore sia al pre-evento che al baseline 2025. La sezione 9 discute i limiti dei modelli di sentiment utilizzati, fondamentali per interpretare correttamente i valori assoluti riportati.

Indice

- Executive Summary
- 1. Introduzione e motivazione
- 2. Fonti, strumenti e librerie utilizzate
- 3. Fase 1 — Dataset e raccolta dati
- 4. Fase 2 — Validazione modelli NLP (opzionale, non eseguita)
- 5. Fase 3 — Preprocessing del testo
- 6. Fase 4 — Analisi NLP
 - 6.1 Analisi del sentiment
 - 6.2 Topic modeling
- 7. Fase 5 — Analisi comparativa
- 8. Fase 6 — Analisi temporale descrittiva
- 9. Validazione empirica in-domain (gold standard)
- 10. Limitazioni
- 11. Conclusioni
- 12. 12. Appendice — Prompt Engineering: uso di LLM come strumento di sviluppo
 - 1. 12.1 Zero-Shot Prompting — Progettazione dello scraper
 - 2. 12.2 Role Prompting + Output Formatting — Etichettatura dei topic LDA
 - 3. 12.3 Chain-of-Thought (CoT) — Selezione del modello di sentiment
 - 4. 12.4 Few-Shot Prompting — Annotazione manuale del gold standard
 - 5. 12.5 Role + CoT + Output Formatting — Interpretazione della divergenza Cagliari/Olbia

1. Introduzione e motivazione

L'America's Cup 2026 è uno degli eventi velici più prestigiosi al mondo e, per la prima volta nella sua storia, vedrà Cagliari come sede delle regate. Questo rappresenta un'opportunità straordinaria per il turismo sardo, ma anche una sfida: la città dovrà gestire un afflusso eccezionale di visitatori in un arco di tempo molto concentrato.

L'obiettivo di questo progetto è **misurare l'impatto percepito dell'evento sulla soddisfazione dei turisti** attraverso l'analisi delle recensioni degli ospiti delle strutture ricettive. La domanda di ricerca centrale è: *le recensioni lasciate dagli ospiti durante il periodo dell'America's Cup mostrano differenze significative rispetto al periodo pre-evento e rispetto all'anno precedente?*

Per rispondere a questa domanda è stata costruita una pipeline di analisi del testo che integra più tecniche di NLP — analisi del sentiment, riconoscimento delle emozioni e topic modeling — applicata a recensioni scrappate da Booking.com.

Perché Booking.com? Booking.com è la principale piattaforma di prenotazione alberghiera in Europa, con un sistema di recensioni verificate (solo chi ha soggiornato può recensire) che garantisce l'autenticità del dato. Le recensioni sono strutturate con un campo positivo e uno negativo, il che semplifica l'analisi del sentiment.

Perché Olbia come città di controllo? Olbia è una città sarda di dimensioni comparabili, anch'essa con una forte vocazione turistica legata al mare e agli eventi estivi, ma non coinvolta nell'America's Cup. Includerla permette di distinguere i trend locali legati all'evento da quelli stagionali generali della Sardegna.

Disegno dello studio in breve:

Dimensione	Trattamento	Controllo
Temporale	2026 (anno dell'evento)	2025 (stesso periodo, anno precedente)
Geografica	Cagliari (sede dell'evento)	Olbia (nessun evento)

Il disegno incrocia queste due dimensioni — confronto longitudinale (2026 vs 2025) e confronto sincronico (Cagliari vs Olbia) — per isolare, nei limiti consentiti da dati osservazionali, l'effetto specifico dell'evento dalla normale stagionalità turistica estiva.

2. Fonti, strumenti e librerie utilizzate

2.1 Fonte dati

Fonte	Utilizzo
Booking.com	Unica piattaforma di raccolta. Scraping di recensioni (testo positivo/negativo, rating, data, provenienza ospite, tipo di soggiorno) per Cagliari e Olbia.

Il file `analysis/config.py` prevedeva inizialmente anche altre sorgenti (`airbnb`, `tripadvisor`, `google`), ma per questioni di tempo e di omogeneità del dato il progetto si è concentrato esclusivamente su `Booking.com`, che da sola garantisce un volume sufficiente (15.509 recensioni) e una struttura dati uniforme tra le due città.

2.2 Strumenti di sviluppo

Strumento	Ruolo nel progetto
Python 3.9+	Linguaggio principale per scraping, preprocessing e analisi
Selenium + ChromeDriver	Automazione del browser per lo scraping di <code>Booking.com</code>
Git	Versionamento del codice e dei risultati
Visual Studio Code	Editor principale
Claude (Claude Code)	Assistente AI utilizzato per la generazione e il debug iterativo degli script di analisi (preprocessing, sentiment, topic modeling, validazione) e per la stesura della documentazione di progetto (<code>README.md</code> , <code>CLAUDE.md</code> , questo report)

2.3 Librerie utilizzate

Le librerie sono organizzate per fase della pipeline, con la motivazione della scelta.

Scraping e raccolta dati

Libreria	Motivazione
selenium	Automazione browser necessaria per gestire contenuti caricati dinamicamente (JavaScript) su Booking.com
beautifulsoup4	Parsing dell'HTML estratto per isolare i campi delle singole recensioni

Preprocessing e gestione dati

Libreria	Motivazione
pandas	Struttura dati principale per la manipolazione tabellare dei dataset
nltk	Tokenizzazione e download risorse
spacy	Lemmatizzazione del testo italiano e inglese
langdetect	Rilevamento automatico della lingua di ciascuna recensione, necessario per il dispatch dei modelli di emozione (Feel-IT emotion per italiano, DistilRoBERTa per inglese)
textblob	Utility di supporto per l'elaborazione testuale
sentencepiece	Dipendenza richiesta dal tokenizer di CamemBERT (Feel-IT)

Sentiment, emozioni e topic modeling

Libreria	Motivazione
transformers	Caricamento dei modelli HuggingFace (nlptown sentiment, Feel-IT emotion, DistilRoBERTa emotion)
datasets	Caricamento dei benchmark pubblici usati nel modulo di validazione (analysis/validation.py)
scikit-learn	Implementazione di LDA (LatentDirichletAllocation), vettorizzazione TF-IDF/Count e metriche di validazione (accuracy, classification report, confusion matrix)
bertopic	Topic modeling basato su embedding semantici
sentence-transformers	Backend per gli embedding multilingua usati da BERTopic

Visualizzazione

Libreria	Motivazione
matplotlib	Generazione di grafici statici (box plot, bar chart, confusion matrix)
seaborn	Heatmap delle confusion matrix e stile grafico uniforme
wordcloud	Word cloud per polarità/finestra/città nel topic modeling

3. Fase 1 — Dataset e raccolta dati

3.1 Scraping con Selenium

La raccolta dati è avvenuta tramite due scraper sviluppati in Python con **Selenium** (`booking_scraper_cagliari.py` e `booking_scraper_olbia.py`), che automatizzano la navigazione del browser per estrarre le recensioni da Booking.com.

Gli scraper supportano inoltre il **checkpoint automatico**: se l'esecuzione viene interrotta, riprendono dalla struttura successiva senza ripartire da zero — una caratteristica importante data la durata delle sessioni di scraping su centinaia di strutture.

Per ogni struttura ricettiva sono stati raccolti i seguenti campi:

Campo	Descrizione
<code>city</code>	Città della struttura
<code>property</code>	Nome della struttura
<code>property_stars</code>	Categoria (stelle)
<code>review_date</code>	Data della recensione
<code>rating</code>	Punteggio numerico (1–10)
<code>review_title</code>	Titolo della recensione
<code>text_positive</code>	Testo della parte positiva
<code>text_negative</code>	Testo della parte negativa
<code>stay_type</code>	Tipologia di soggiorno (coppia, famiglia, ecc.)
<code>nights_stayed</code>	Numero di notti
<code>reviewer_country</code>	Paese del recensore

Nota sullo schema colonne: lo scraper produce nomi di colonna leggermente diversi da quelli usati internamente dalla pipeline di analisi (`city` → `property_city`, `source` → `scrape_source`, `property` → `property_name`). È stata presa la decisione progettuale di **non rinominare le colonne né ri-scrapare**, normalizzando invece gli alias direttamente negli script di analisi (`comparative.py`, `sentiment_analysis.py`, `topic_modeling.py`).

3.2 Finestre temporali

Le finestre temporali sono state definite attorno alle date ufficiali delle regate:

Finestra	Periodo 2026	Periodo baseline 2025
pre	1 apr – 20 mag	1 apr – 20 mag
during	21 mag – 24 mag	21 mag – 24 mag
post	25 mag – 15 giu	25 mag – 15 giu

Il confronto 2026 vs 2025 (stesso periodo, anno precedente) permette di isolare l'effetto evento dalla normale stagionalità. L'assegnazione della finestra avviene sulla base di `review_date` (la data di pubblicazione della recensione).

3.3 Composizione del dataset

Il dataset finale contiene **15.509 recensioni** distribuite come segue:

Città	Finestra	2026	2025 (baseline)
Cagliari	pre	5.090	4.256
Cagliari	during	333	184
Cagliari	post	942	1.452
Olbia	pre	2.048	—
Olbia	during	86	—
Olbia	post	1.028	—

La baseline di Olbia 2025 non è stata raccolta per scelta progettuale: l'analisi comparativa di Olbia serve come controllo sincronico (stesso periodo, città diversa) piuttosto che longitudinale.

4. Fase 2 — Validazione modelli NLP su benchmark pubblici

La pipeline prevede uno step di validazione dei modelli NLP su benchmark pubblici esterni, tramite **analysis/validation.py**. Lo script valida i modelli su dati indipendenti dal corpus del progetto, in modo da quantificarne le prestazioni fuori dal dominio delle recensioni alberghiere.

Modello	Benchmark esterno	Split	n
nlptown sentiment (italiano)	mteb/tweet_sentiment_multilingual	Italiano	500
nlptown sentiment (inglese)	mteb/tweet_sentiment_multilingual	Inglese	500
Feel-IT emotion (italiano)	dair-ai/emotion (proxy inglese)	—	500

Per ciascun modello, lo script campiona 500 esempi (`random_state=42`, `batch_size=8`, CPU), normalizza le etichette in uno schema a tre classi (`positive/negative/neutral`), calcola `accuracy/F1 macro/weighted` e salva una confusion matrix in `results/validation/`.

Stato: eseguito (`python -m analysis.validation`). I risultati completi sono riportati nella sezione 9.4.

5. Fase 3 — Preprocessing del testo

Il testo grezzo delle recensioni richiede una fase di pulizia prima di poter essere analizzato. Il modulo `analysis/preprocessing.py` esegue i seguenti step:

1. **Unificazione dei testi:** i campi `text_positive` e `text_negative` vengono trattati separatamente e poi uniti con un flag `has_negative` che indica la presenza di una sezione negativa.

2. **Rilevamento della lingua:** tramite la libreria `langdetect`, ogni recensione viene classificata come italiana o inglese. Questo è essenziale perché i modelli di sentiment sono specifici per lingua.
3. **Pulizia del testo:** rimozione di punteggiatura, caratteri speciali, numeri e spazi multipli.
4. **Lemmatizzazione:** le parole vengono ridotte alla loro forma base (es. “camere” → “camera”, “dormito” → “dormire”) tramite **spaCy**, usando i modelli `it_core_news_sm` per l’italiano e `en_core_web_sm` per l’inglese.
5. **Feature engineering:** calcolo della lunghezza della recensione (`review_length`) e assegnazione della finestra temporale (`temporal_window`) basata sulla data di recensione.

6. Fase 4 — Analisi NLP

6.1 Analisi del sentiment (nlptown per tutte le lingue)

L’analisi del sentiment è il cuore del progetto. Data la natura multilingue del dataset (recensioni in italiano e inglese), è stato adottato un approccio con modelli specializzati per lingua.

6.1.1 Modello utilizzato

`nlptown/bert-base-multilingual-uncased-sentiment` è un BERT multilingua (`bert-base-multilingual-uncased`) fine-tuned su recensioni reali di prodotti in sei lingue (tedesco, inglese, olandese, francese, italiano, spagnolo). Classifica il testo in **1–5 stelle**, mappate internamente alla pipeline come segue:

Stelle predette	Label	Score
1 star	negative	−1.0
2 stars	negative	−0.5
3 stars	neutral	0.0
4 stars	positive	+0.5
5 stars	positive	+1.0

Il modello è stato scelto a seguito della validazione empirica (sezione 9), che ha confrontato `Feel-IT` e `nlptown` su un gold standard di 150 recensioni annotate manualmente: `nlptown` ha mostrato accuracy del 96% (contro 58% di `Feel-IT`) e score più coerenti con i rating numerici del dataset. La sua architettura multilingua, addestrata specificamente su recensioni, si adatta meglio del dominio `tweet` di `Feel-IT` al registro delle recensioni alberghiere di `Booking.com`. Viene usato per tutte le lingue del dataset (italiano e inglese).

6.1.2 Risultati del sentiment

Sentiment medio per città (2026):

Città	Sentiment medio	Recensioni
Cagliari	+0.713	12.347
Olbia	+0.622	3.162

Con nlptown, i sentiment score sono distribuiti nell'intervallo $[-1, +1]$ in base al numero di stelle predette. Il sentiment score medio superiore a +0.70 per Cagliari indica che la maggioranza delle recensioni riceve 4–5 stelle dal modello, coerente con i rating numerici medi del dataset (superiori a 8/10).

Sentiment medio per finestra temporale:

Finestra	Anno	Sentiment medio	Recensioni
pre	2026	+0.697	7.138
during	2026	+0.631	419
post	2026	+0.601	1.970
baseline_pre	2025	+0.743	4.256
baseline_during	2025	+0.794	184
baseline_post	2025	+0.672	1.452

Il dato più rilevante è il confronto del periodo during: nel 2025 il sentiment medio era +0.794, mentre nel 2026 scende a +0.631 (–20.5%). Il sentiment rimane positivo in entrambi gli anni, ma il calo significativo durante l'evento suggerisce che la pressione turistica ha influenzato negativamente la soddisfazione degli ospiti rispetto all'anno precedente.

6.2 Topic modeling (LDA + BERTopic)

Dopo aver quantificato *il tono* delle recensioni con l'analisi del sentiment, il passo successivo è capire *di cosa parlano* — ovvero quali temi guidano le valutazioni positive e negative, e se questi temi cambiano in funzione dell'evento. Il topic modeling permette di identificare i **temi ricorrenti** nelle recensioni in modo non supervisionato — senza cioè definire a priori le categorie. Sono stati applicati due approcci complementari, eseguiti separatamente sulla parte positiva e negativa di ogni recensione (polarity).

6.2.1 LDA (Latent Dirichlet Allocation)

LDA è un modello probabilistico generativo che assume che ogni documento sia una miscela di topic latenti, e ogni topic sia una distribuzione di parole. Parametri usati:

- **10 topic** per polarità (positivo/negativo), per un totale di 20 modelli (uno per ogni combinazione città × finestra)

I topic positivi estratti (da `results/lda_top_words.csv`) descrivono principalmente:

Topic	Parole chiave	Interpretazione
0	comodo, stanza, molto, colazione, posizione, pulito, bagno, ampio	Comfort della camera
1	posizione, pulizia, perfetto, ottimo, stazione, vicino, città, accoglienza, ambiente, staff	Posizione e accoglienza
2	posizione, ottimo, centro, molto	Centralità
5	posizione, camera, centro, gentilezza, pulizia	Centralità e qualità del personale
8	ottimo, posizione, pulito, colazione, gentile	Topic generale positivo

I topic negativi riflettono le criticità più comuni:

Topic	Parole chiave	Interpretazione
1	camera, rumore, rumoroso, scale	Rumorosità
2	stanza, insonorizzazione, chiudere	Isolamento acustico
3	bagno, piccolo, doccia, asciugamano	Dimensioni e dotazioni bagno
6	parcheggio, trovare, mancare	Difficoltà di parcheggio
8	nulla, niente, perfetto, segnalare, particolare	Assenza di critiche (recensioni senza lamentele)

Dalla tabella `results/topics_by_city.csv`, il **topic positivo 8** è il più frequente in entrambe le città (2.597 occorrenze a Cagliari, 640 a Olbia), seguito dal topic 1 (1.176 a Cagliari, 245 a Olbia). Sul lato negativo, il **topic 8** domina per occorrenze (2.005 a Cagliari, 491 a Olbia), ma le sue parole chiave — *nulla, niente, perfetto, segnalare, particolare* — rivelano che si tratta di **recensioni prive di lamentele reali**. Il suo dominio è un indicatore positivo. La principale criticità reale è il **topic 1** (rumore, rumoroso, scala), secondo per frequenza in entrambe le città — coerente con la rumorosità come criticità trasversale.

Il **topic positivo 8** è il dominante in tutte le finestre temporali sia per Cagliari che per Olbia (`results/topics_by_window.csv`), confermando che la qualità percepita della struttura (pulizia, posizione, cortesia del personale) è stabile e indipendente dall'evento.

LDA — Distribuzione topic per città (Cagliari vs Olbia)




Figura — Occorrenze dei 10 topic LDA per Cagliari e Olbia, divise per polarità. Il topic 8 (bordo nero) domina su entrambe le polarità e città. Sul lato negativo, T8 cattura recensioni senza lamentele reali; la principale criticità reale è T1 (rumorosità).

6.2.2 BERTopic

BERTopic è un approccio più moderno che utilizza gli **embeddings semantici** prodotti da un transformer multilingua (paraphrase-multilingual-MiniLM-L12-v2) per raggruppare i documenti in cluster semanticamente coerenti, applicando poi TF-IDF per estrarre le parole rappresentative di ogni cluster. Rispetto a LDA, BERTopic cattura meglio le relazioni semantiche tra parole (es. “ottimo” e “eccellente” vengono trattate come simili, non come parole indipendenti).

Dai risultati (results/bertopic_top_words.csv), il **topic 0** — *posizione, molto, ottimo, camera, colazione, pulito, pulizia, centro, stanza, comodo* — è il cluster largamente dominante sul lato positivo (9.160 occorrenze a Cagliari), confermando con un metodo indipendente la centralità del fattore “posizione + pulizia + colazione” già emerso con LDA. Il topic -1 (outlier/non assegnato) di BERTopic è invece il più numeroso sul lato negativo (6.072 a Cagliari, 1.194 a Olbia), il che è

tipico di BERTopic su testi negativi brevi e molto eterogenei, dove non emerge un cluster semantico dominante.

Le figure seguenti mostrano la distribuzione dei cluster BERTopic per le due polarità, con dimensione delle bolle proporzionale alle occorrenze totali (Cagliari + Olbia).




Figura — Cluster di topic positivi (BERTopic). Il topic 0 (posizione, pulizia e colazione) domina nettamente. Le bolle grigie rappresentano outlier o noise.




Figura — Cluster di topic negativi (BERTopic). Il topic “nessuna critica” (viola) è il secondo per dimensione. La principale criticità reale è rumore e parcheggio (topic 0).

6.2.3 Visualizzazioni

Le wordcloud generate mostrano i termini più frequenti per ogni combinazione città × finestra × polarità (20 immagini in results/topic_modeling/). Di seguito alcuni esempi rappresentativi.

Wordcloud positiva — Cagliari, periodo pre-evento 2026:



Wordcloud positiva Cagliari pre

Figura 1. Termini più frequenti nelle recensioni positive di Cagliari nel periodo pre-evento ($n = 4.937$ recensioni). **Take-away:** posizione, pulizia e colazione sono i temi che guidano la soddisfazione anche prima dell’evento.

Wordcloud negativa — Cagliari, periodo durante l'evento 2026:



Wordcloud negativa Cagliari during

Figura 2. Termini più frequenti nelle recensioni negative di Cagliari durante l'evento (n = 137 recensioni). **Take-away:** emergono con maggiore frequenza riferimenti a rumore e traffico, criticità tipiche di un forte afflusso turistico concentrato.

Wordcloud positiva — Olbia, periodo pre-evento 2026:



Wordcloud positiva Olbia pre

*Figura 3. Termini più frequenti nelle recensioni positive di Olbia nel periodo pre-evento (n = 1.976 recensioni), usata come riferimento di confronto. **Take-away:** i temi positivi sono molto simili a quelli di Cagliari, confermando che posizione e pulizia sono driver di soddisfazione generali e non specifici dell'evento.*

Durante il periodo dell'evento a Cagliari emergono nella sezione negativa termini legati al **rumore** e al **traffico**, assenti o meno frequenti nel periodo baseline. Questo è coerente con l'afflusso straordinario di visitatori che caratterizza un evento di questa portata.

7. Fase 5 — Analisi comparativa

Il modulo `analysis/comparative.py` aggrega i risultati di sentiment e topic modeling per rispondere alle domande di ricerca principali.

7.1 Analisi volumetrica

Il numero di recensioni è un proxy dell'afflusso turistico. Il confronto 2026 vs 2025 mostra:

Finestra	2026	2025	Variazione
pre	5.090	4.256	+19.6%
during	333	184	+81.0%
post	942	1.452	-35.1%

L'aumento delle recensioni nel periodo during (+81%) riflette chiaramente l'incremento degli arrivi legato all'evento. Il calo nel periodo post (-35.1%) è probabilmente dovuto al fatto che lo scraping è avvenuto in procinto della fine del periodo post (15 giugno 2026), e non tutte le recensioni relative a soggiorni recenti erano ancora state pubblicate al momento della raccolta.




Figura: Confronto del volume di recensioni tra baseline 2025 (grigio) e America's Cup 2026 (nero) nelle tre finestre temporali. Il picco del +81% nel periodo during evidenzia l'impatto diretto dell'evento sull'afflusso turistico. Il calo del -35.1% nel periodo post va letto con cautela: lo scraping è avvenuto a ridosso della chiusura della finestra (15 giugno 2026), e una quota delle recensioni relative a soggiorni recenti non era ancora disponibile al momento della raccolta.

7.2 Sentiment comparativo Cagliari vs Olbia

Periodo pre-evento (2026):

Città	Sentiment medio	% Positivo	% Negativo	% Neutro
Cagliari	+0.702	89.9%	1.6%	8.5%
Olbia	+0.683	88.3%	3.3%	8.4%

Periodo durante l'evento (2026):

Città	Sentiment medio	% Positivo	% Negativo	% Neutro
Cagliari	+0.563	73.3%	0.3%	26.4%
Olbia	+0.895	95.4%	1.2%	3.5%

Periodo post-evento (2026):

Città	Sentiment medio	% Positivo	% Negativo	% Neutro
Cagliari	+0.736	90.7%	0.4%	8.9%
Olbia	+0.477	75.2%	8.0%	16.8%

Il dato più interessante è la **divergenza tra Cagliari e Olbia durante l'evento**: il sentiment di Olbia sale a +0.895 (il valore più alto fra tutti i periodi e città), mentre Cagliari scende a +0.563, il valore più basso del 2026 per questa città. La forte crescita della quota “neutro” a Cagliari (26.4% vs 8.5% nel pre) indica che molte recensioni si collocano su 3 stelle — un segnale di soddisfazione ridotta coerente con la pressione da sovraffollamento.




Figura: Evoluzione del sentiment score medio nelle tre finestre temporali. Le due città partono su valori simili nel pre-evento e divergono nettamente durante l'America's Cup: Cagliari tocca il minimo (+0.563) mentre Olbia raggiunge il massimo assoluto (+0.895). Nel post-evento la situazione si inverte.

Distribuzione sentiment: Cagliari vs Olbia per finestra temporale




Figura: Composizione delle recensioni (positivo / neutro / negativo) per città e finestra temporale. La quota "neutro" di Cagliari durante l'evento (26.4%) è quasi triplicata rispetto al pre (8.5%), segnale di soddisfazione ridotta coerente con la pressione da sovraffollamento.

Heatmap sentiment medio: Cagliari vs Olbia




Figura: Heatmap del sentiment medio (scala verde-rosso). La cella Olbia/Durante è la più verde (+0.895) e Cagliari/Durante la più rossa (+0.563), rendendo visivamente immediata la divergenza sincronica tra le due città.

Sentiment medio per finestra temporale: Cagliari vs Olbia




Figura: Small multiples per finestra temporale. Ogni pannello confronta direttamente Cagliari (blu) e Olbia (arancione), rendendo leggibile la parità nel pre, l'inversione durante l'evento, e il nuovo ribaltamento nel post.

7.3 Topic dominanti per finestra temporale

Il **topic positivo 8** — caratterizzato da termini come *ottimo, posizione, pulito, colazione, gentile* — risulta dominante in tutte le finestre temporali per entrambe le città, suggerendo che il fattore qualità struttura è stabile e non viene spostato dall'evento. Sul lato negativo, il topic 8 (recensioni senza lamentele) domina per volume, ma la criticità reale più ricorrente rimane il **topic 1** (rumorosità), presente in modo trasversale a tutte le finestre temporali.

Tuttavia, durante il periodo dell'America's Cup, il **topic 0** (camera, colazione, posizione) guadagna peso a scapito del **topic 2** (centro, disponibile, struttura), suggerendo uno spostamento dell'attenzione verso i comfort di base — coerente con un'esperienza di soggiorno più affollata e meno rilassata.

**Topic negativi (LDA) — distribuzione per finestra temporale
(escluso T8: recensioni senza lamentele)**





Figura: Heatmap della distribuzione percentuale dei topic negativi (LDA) nelle tre finestre temporali. Il topic 8 (recensioni senza lamentele) è escluso per far emergere il segnale reale. Il rosso intenso su T0 (camera/colazione/posizione, 24.4%) e T4 (prezzo/rapporto qualità-prezzo, 21.2%) durante l'evento evidenzia con chiarezza il disagio percepito dai turisti nel periodo dell'America's Cup, in netto contrasto con i valori pre e post.

8. Fase 6 — Analisi temporale descrittiva

Mentre le sezioni precedenti hanno analizzato sentiment e topic in forma aggregata, questa sezione adotta una prospettiva puramente descrittiva e temporale, confrontando le distribuzioni di rating e sentiment tra le finestre pre/during/post e, per Cagliari, tra il 2026 e il baseline 2025.

8.1 Rating per finestra temporale (2026)

Il box plot seguente mostra la distribuzione dei rating per le tre finestre temporali, separata per città:



Box plot rating per finestra temporale

Figura 4. Distribuzione del rating (1-10) per finestra temporale (pre/during/post) e città, con media (◆) e numerosità campionaria indicate. **Take-away:** a Cagliari il rating medio scende durante l'evento (8.65 vs 9.20 nel pre) e mostra maggiore variabilità, mentre a Olbia il pattern è opposto.


Osservazioni principali (da results/exploratory/temporal_summary.csv):

Città	Finestra	n	Rating medio	Std	Sentiment medio
Cagliari	pre	93.878	9.204	0.888	+0.699
Cagliari	during	6.045	8.650	1.134	+0.545
Cagliari	post	10.064	9.156	0.933	+0.762
Olbia	pre	34.018	8.842	1.063	+0.684
Olbia	during	1.188	9.643	0.493	+0.992
Olbia	post	16.654	8.695	1.145	+0.437

Nota: gli n di questa tabella sono righe del dataset *merged* con il topic modeling (espanso, più topic per recensione), non recensioni uniche — vanno letti come pesi relativi, non come conteggi di recensioni.

- A Cagliari il rating medio **scende durante l'evento** (8.65) rispetto al pre (9.20) e risale nel post (9.16); lo stesso pattern emerge nel sentiment (+0.699 → +0.545 → +0.762)
- La deviazione standard del rating aumenta durante l'evento (1.134 vs 0.888 nel pre), indicando maggiore variabilità nelle esperienze
- Olbia mostra un pattern opposto: sia il rating (9.643) sia il sentiment (+0.992) durante l'evento sono i valori più alti dei tre periodi, ma il campione è molto ridotto (n=1.188 righe, corrispondenti a 86 recensioni uniche)

8.2 Sentiment per finestra temporale (2026)




Box plot sentiment per finestra temporale

*Figura 5. Distribuzione del sentiment score per finestra temporale e città. **Take-away:** a Cagliari il sentiment scende durante l'evento (+0.545 vs +0.699 nel pre) e recupera nel periodo post (+0.762), mentre Olbia mostra il valore massimo proprio durante l'evento (+0.992).*

Il sentiment score conferma il pattern del rating: a Cagliari il valore più basso del 2026 si registra nel periodo during (+0.545), mentre il post-evento (+0.762) supera il pre (+0.699) — un effetto “rimbalzo” positivo dopo la pressione del periodo di gara.

8.3 Confronto 2026 vs baseline 2025 — Cagliari

Il grafico seguente è il risultato più direttamente rilevante per la domanda di ricerca: confronta rating e sentiment medi nelle stesse finestre temporali tra il 2026 (anno dell’America’s Cup) e il 2025 (anno di riferimento):



Confronto Cagliari 2026 vs 2025

Figura 6. Confronto diretto, per Cagliari, tra rating e sentiment medi nel 2026 (anno dell'evento) e nello stesso periodo del 2025 (baseline), con numerosità campionaria indicata. **Take-away:** il periodo *during* mostra il calo più marcato rispetto al baseline (sentiment da +0.79 a +0.56, -29%), mentre il periodo *post* 2026 supera il baseline 2025.

Interpretazione:

- **Rating:** nel periodo *during*, il rating medio 2026 è più basso rispetto al 2025 (8.65 vs ~8.9 nel 2025). Nel periodo *post*, il 2026 registra valori leggermente superiori al 2025.
- **Sentiment:** il calo più marcato si registra nel periodo *during*, dove il sentiment 2025 era +0.794 mentre il 2026 scende a +0.563 (-29%). Nel 2025, fine maggio era un periodo tranquillo; nel 2026 l'afflusso dell'evento ha introdotto fonti di insoddisfazione, pur senza portare il sentiment in territorio negativo.

Il periodo *post* 2026 mostra un sentiment di +0.736, superiore al baseline 2025 (+0.672): chi soggiorna dopo l'evento tende a lasciare recensioni più positive, probabilmente perché la pressione turistica si è allentata mentre l'entusiasmo per la città rimane alto.

9. Validazione empirica in-domain (gold standard)

Per quantificare l'affidabilità dei risultati di sentiment, è stata condotta una validazione empirica **in-domain** su un campione di recensioni annotato manualmente. Sono stati confrontati **due modelli**: Feel-IT (MilanNLP/feel-it-italian-sentiment) e nlptown/bert-base-multilingual-uncased-sentiment. I risultati della validazione hanno guidato la scelta di adottare **nlptown come modello principale** della pipeline (sezione 6.1), sostituendo Feel-IT per il sentiment italiano e VADER per l'inglese — nlptown gestisce ora tutte le lingue con un unico modello.

9.1 Costruzione del gold standard

Lo script `analysis/generate_gold_standard.py` ha selezionato casualmente **150 recensioni in italiano** dal corpus di Cagliari, campionando 30 recensioni per finestra temporale (*pre*, *during*,

post, baseline_pre, baseline_during) per garantire una distribuzione bilanciata. Le righe sono state mescolate in ordine casuale (random_state=42) per evitare bias di posizione nella fase di annotazione.

Per ogni recensione sono stati inclusi: id progressivo, finestra temporale, data, rating numerico, text_positive e text_negative. L'annotazione manuale ha assegnato l'etichetta **positive** o **negative** basandosi sulla lettura del testo e sul rating, seguendo questo criterio:

- Rating ≥ 8 con testo positivo dominante → **positive**
- Rating 6 con testo negativo esplicito e forte → **negative**
- Rating 7 con reclami significativi nel text_negative → **negative**

Distribuzione del gold standard (n=150):

Etichetta	Conteggio	%
positive	147	98.0%
negative	3	2.0%

Lo sbilanciamento riflette la distribuzione reale del corpus: le recensioni su Booking.com sono strutturalmente orientate verso la valutazione positiva, con rating mediamente alti.

9.2 Inferenza e risultati: Feel-IT vs nlptown

Lo script analysis/empirical_validation.py ha applicato entrambi i modelli sui 150 testi del gold standard.

9.2.1 Feel-IT (MiLaNLP/feel-it-italian-sentiment)

Metriche complessive:

Metrica	Valore
Accuracy	58.0%
Macro F1	0.395
Weighted F1	0.716


Precision / Recall / F1 per classe:

Classe	Precision	Recall	F1	n
negative	0.031	0.667	0.060	3
positive	0.988	0.578	0.730	147

Accuracy per finestra temporale:

Finestra	n	Accuracy
baseline_during	30	50.0%
baseline_pre	30	56.7%
during	30	66.7%
post	30	60.0%
pre	30	56.7%


Confusion Matrix — Feel-IT vs. Annotazione Umana



Confusion matrix Feel-IT

Figura 7. Confusion matrix di Feel-IT sul gold standard di 150 recensioni annotate manualmente.

Take-away: il modello identifica correttamente 2 dei 3 casi negativi reali (recall 66.7%), ma a costo di 62 falsi positivi sulla classe positiva (precision 3.1%).



Accuracy per finestra temporale Feel-IT

Figura 8. Accuracy di Feel-IT calcolata separatamente per ciascuna delle 5 finestre temporali del gold standard (30 recensioni ciascuna), con la media complessiva indicata dalla linea tratteggiata.

Take-away: l'accuracy oscilla tra il 50% e il 66.7% in tutte le finestre, segno di un errore sistematico del modello indipendente dal periodo considerato.

9.2.2 nlptown (nlptown/bert-base-multilingual-uncased-sentiment)

nlptown/bert-base-multilingual-uncased-sentiment è un BERT multilingua (bert-base-multilingual-uncased) fine-tuned su recensioni di prodotti in sei lingue (incluso l'italiano), che restituisce una classificazione a **5 stelle** (1-5). Per renderlo comparabile con l'etichettatura binaria del gold standard, l'output è stato mappato tramite _MAPPA_STELLE:

Stelle predette	Etichetta mappata
1 star, 2 stars	negative
3 stars, 4 stars, 5 stars	positive

Questa mappatura è volutamente **conservativa**: anche un giudizio “medio” (3 stelle) viene contato come positivo, il che favorisce la classe maggioritaria del gold standard.


Metriche complessive:

Metrica	Valore
Accuracy	96.0%
Macro F1	0.490
Weighted F1	0.960

Precision / Recall / F1 per classe:

Classe	Precision	Recall	F1	n
negative	0.000	0.000	0.000	3
positive	0.980	0.980	0.980	147

Confusion Matrix — nlptown vs. Annotazione Umana



Confusion matrix nlptown

Figura 9. Confusion matrix di nlptown sul medesimo gold standard. **Take-away:** nlptown non identifica correttamente nessuno dei 3 casi negativi reali (recall 0%): l'accuracy del 96% è quindi quasi interamente dovuta al peso della classe positiva maggioritaria.

9.3 Confronto tra i due modelli: perché l'accuracy da sola è ingannevole

Tabella di confronto (validation/outputs/confronto_modelli.csv):

Modello	Accuracy	Macro F1	Weighted F1
Feel-IT (MilaNLProc)	58.0%	0.395	0.716
nlptown (bert-multilingual)	96.0%	0.490	0.960

A prima vista, nlptown sembra nettamente superiore: 96% di accuracy contro il 58% di Feel-IT. Ma la confusion matrix racconta una storia diversa. Su 3 recensioni realmente negative, **nlptown non ne identifica correttamente nessuna** (precision = recall = 0 sulla classe negative): tutte le

3 vengono classificate come positive. Il 96% di accuracy è quindi quasi interamente un **artefatto della classe maggioritaria** — nlptown si comporta, su questo gold standard, in modo simile a un classificatore banale che predice sempre “positive” (che otterrebbe 147/150 = 98.0% di accuracy).

Feel-IT, al contrario, individua correttamente 2 delle 3 recensioni negative (recall = 0.667), ma al prezzo di un numero enorme di falsi positivi sulla classe negativa: 62 delle 147 recensioni realmente positive vengono etichettate come negative (precision = 0.031).

In altre parole: **nessuno dei due modelli gestisce bene la classe negativa minoritaria** in questo dominio, ma i due falliscono in modo opposto — nlptown ignora completamente i casi negativi (falsi negativi), Feel-IT li “trova” ma sommerso da falsi positivi. Il **Macro F1** (che pesa le due classi in modo uguale, indipendentemente dalla loro numerosità) rende questo compromesso più visibile: 0.395 per Feel-IT vs 0.490 per nlptown — una differenza molto più contenuta del salto di accuracy (58% vs 96%), e nessuno dei due valori è alto in assoluto.

Lezione metodologica: con un gold standard fortemente sbilanciato (147 positivi su 150, 98%), l’accuracy premia qualsiasi modello tenda a predire la classe maggioritaria, indipendentemente dalla sua reale capacità di distinguere le classi. Il Macro F1 (o, in alternativa, Precision/Recall per classe) è la metrica più informativa in questo contesto.

Questo comportamento di Feel-IT è spiegabile dalla differenza di dominio di training: Feel-IT è addestrato principalmente su **tweet italiani**, caratterizzati da un registro informale, ironico e spesso aggressivo. Le recensioni alberghiere di Booking.com hanno invece un registro più neutro e descrittivo, con frasi negative spesso formulate in modo moderato (es. “la zona non è sicurissima di notte”, “mancanza di parcheggio”). Il modello interpreta questi costrutti come negativi, anche quando l’esperienza complessiva dell’ospite è stata soddisfacente. nlptown, addestrato su recensioni di prodotti reali, ha un registro più vicino a quello di Booking.com, ma la sua mappatura a 5 stelle — combinata con uno sbilanciamento di classe estremo nel gold standard — lo rende incapace di segnalare i (pochi) casi negativi.

Conseguenze per l’analisi del sentiment del progetto (che usa **nlptown** come modello principale per l’italiano, a seguito di questa validazione):

- I valori assoluti di sentiment con nlptown (es. +0.713 medio per Cagliari) sono più direttamente interpretabili rispetto a Feel-IT, poiché derivano da una mappatura lineare del numero di stelle predette — registro simile a quello dei rating numerici di Booking.com.
- I **confronti relativi** (Cagliari during 2026 vs during 2025, Cagliari vs Olbia) rimangono la metrica più affidabile: il bias sistematico del modello verso la classe positiva si applica uniformemente a tutte le finestre e città, rendendo le *differenze* tra gruppi più robuste dei valori assoluti.
- La direzione dei trend osservati (calo durante l’evento, recupero post-evento) è coerente con le variazioni del rating numerico, misura indipendente dall’NLP e non soggetta allo stesso bias.
- Il principale limite residuo di nlptown è la **scarsa sensibilità alla classe negativa** (recall 0% su 3 casi nel gold standard): il modello tende a predire sempre “positive” per le recensioni alberghiere, rendendo poco affidabile il conteggio assoluto di recensioni negative (sezioni 7.2 e 6.2, topic negativi). I trend relativi rimangono comunque informativi.

10. Limitazioni

I risultati presentati vanno letti alla luce delle seguenti limitazioni metodologiche, che non invalidano le conclusioni principali ma ne definiscono i confini di interpretazione:

1. **Scarsa sensibilità alla classe negativa di nlptown:** la validazione empirica (sezione 9) ha evidenziato che nlptown ottiene il 96% di accuracy ma recall = 0% sulla classe negativa (0 dei 3 casi negativi identificati). Il modello tende a predire sistematicamente “positive”, il che ne limita l'utilità per individuare le recensioni critiche. I confronti relativi tra finestre/città rimangono validi (il bias è sistematico), mentre i conteggi assoluti di recensioni negative (sezioni 7.2 e 6.2) vanno interpretati con cautela.
2. **Sbilanciamento del gold standard:** 147 esempi positivi contro 3 negativi (98%/2%) rendono le metriche sulla classe negativa (Precision 3.1%, n=3) statisticamente poco robuste — un singolo errore di classificazione pesa per ~33 punti percentuali su quella classe.
3. **Periodo post parziale:** lo scraping è avvenuto in prossimità della fine della finestra post (15 giugno 2026), quindi una parte delle recensioni relative a soggiorni post-evento non era ancora disponibile al momento della raccolta. La diminuzione del -35.1% rispetto al 2025 nel periodo post (sezione 7.1) va letta anche alla luce di questo effetto, non solo come segnale di calo reale degli arrivi.
4. **Assenza della baseline 2025 per Olbia:** la città di controllo dispone solo dei dati 2026, il che limita il confronto longitudinale per Olbia al solo confronto sincronico con Cagliari (sezione 7.2), senza poter verificare se anche Olbia abbia subito variazioni anno su anno indipendenti dall'evento.
5. **Singola fonte dati:** l'analisi si basa esclusivamente su Booking.com. Altre piattaforme (TripAdvisor, Google Reviews, Airbnb), originariamente previste in `config.py`, non sono state integrate; il profilo demografico e le aspettative degli utenti Booking.com potrebbero non essere rappresentativi dell'insieme dei visitatori.

11. Conclusioni

Questo progetto ha dimostrato come le recensioni online possano essere usate come strumento di **misurazione dell'impatto di un grande evento** sulla percezione turistica di una città.

Risultati principali

1. **Aumento degli arrivi:** il numero di recensioni durante l'America's Cup è aumentato dell'81% rispetto allo stesso periodo 2025, confermando l'impatto volumetrico dell'evento.
2. **Peggioramento del sentiment durante l'evento:** il rating medio a Cagliari scende da 9.20 (pre) a 8.65 (during), e il sentiment passa da +0.699 a +0.545. Il confronto con il baseline 2025 è ancora più marcato: +0.794 nel 2025 contro +0.563 nel 2026 (-29%).

3. **Recupero post-evento:** dopo le regate, il sentiment a Cagliari sale a +0.762, il valore più alto del 2026 per questa città e superiore al baseline 2025 (+0.672), suggerendo un effetto “coda positiva” dell’evento sull’immagine della destinazione.
4. **Olbia come controllo:** la città di controllo non mostra il peggioramento di Cagliari durante l’evento (anzi, mostra il rating medio più alto dei tre periodi), confermando che il segnale rilevato è specifico della città ospitante.
5. **Topic stabili:** i temi ricorrenti (posizione, pulizia, personale, colazione) non cambiano sostanzialmente tra le finestre temporali — confermato sia da LDA che da BERTopic — ma durante l’evento emergono segnali di critica verso rumore e traffico.

Stack tecnologico — riepilogo

Componente	Tecnologia
Scraping	Python, Selenium
Preprocessing	spaCy, NLTK, langdetect
Sentiment IT	nlptown (bert-base-multilingual-uncased-sentiment)
Sentiment EN	nlptown (stesso modello dell’italiano)
Emozioni IT	Feel-IT emotion
Emozioni EN	DistilRoBERTa (Hartmann et al.)
Topic modeling	LDA (scikit-learn), BERTopic
Embeddings	paraphrase-multilingual-MiniLM-L12-v2
Validazione	scikit-learn (metrics), gold standard in-domain (150 rec.) — Feel-IT vs nlptown; adozione di nlptown a seguito dei risultati; benchmark HuggingFace (datasets) per step futuri
Visualizzazioni	matplotlib, seaborn, wordcloud, pyLDAvis

Report generato a partire dai risultati della pipeline di analisi disponibile nel repository del progetto.

12. Appendice — Prompt Engineering: uso di LLM come strumento di sviluppo

Durante lo sviluppo del progetto, modelli linguistici di grandi dimensioni (LLM) — in particolare Claude (Anthropic) — sono stati utilizzati come strumento di supporto in diverse fasi: progettazione del codice, interpretazione dei risultati, scelta del modello NLP e stesura del report. Questa appendice documenta i prompt principali impiegati, esplicitando le tecniche di prompt engineering adottate per ottenere output accurati e contestualizzati.

Le tecniche illustrate sono: zero-shot prompting, few-shot prompting, chain-of-thought (CoT), role prompting e output formatting. Ogni prompt è accompagnato da una nota metodologica che ne giustifica la struttura.

12.1 Zero-Shot Prompting — Progettazione dello scraper

Contesto: fase iniziale del progetto, necessità di costruire un web scraper per Booking.com con Selenium.

Tecnica: zero-shot — il modello riceve solo la descrizione del compito, senza esempi. Adatto a task ben definiti in cui il modello ha già competenza sufficiente nel dominio.

```
Scrivi uno script Python con Selenium che scarica le recensioni degli hotel di
Cagliari
da Booking.com. Per ogni recensione estrai i seguenti campi:
- nome dell'hotel e numero di stelle
- data della recensione
- rating numerico (scala 1-10)
- testo positivo e testo negativo separati
- paese del recensore, tipo di soggiorno e numero di notti

Requisiti:
- gestisci il lazy loading e la paginazione (più pagine di risultati)
- salva l'output in un file CSV con header
- aggiungi retry in caso di timeout
- usa waits espliciti (WebDriverWait) invece di time.sleep()
```

Perché funziona: la richiesta è strutturata per bullet point con requisiti tecnici espliciti. Lo zero-shot funziona bene qui perché Selenium e Booking.com sono nel training del modello, e la specifica chiara dei campi limita l'ambiguità dell'output.

12.2 Role Prompting + Output Formatting — Etichettatura dei topic LDA

Contesto: dopo l'esecuzione di topic_modeling.py, i 10 topic LDA sono rappresentati come liste di keyword. Necessario assegnare un'etichetta semantica leggibile a ciascuno.

Tecnica: role prompting (assegna un ruolo esperto al modello) combinato con output formatting (specifica del formato esatto dell'output). Riduce la vaghezza e produce output direttamente utilizzabile nel codice.

```
Sei un linguista computazionale esperto di topic modeling applicato al turismo.
Ti fornisco le 10 parole più rappresentative di ciascun topic estratto tramite LDA
da recensioni di hotel italiani (corpus: ~15.000 recensioni, Booking.com).

Per ogni topic assegna un'etichetta semantica breve (massimo 4 parole).
Restituisci i risultati ESATTAMENTE nel formato Python seguente, senza testo
aggiuntivo:

TOPIC_LABELS_POSITIVE = {
    0: "etichetta",
    1: "etichetta",
    ...
}
```

```
Topic positivi (termini ordinati per peso):
- Topic 0: ottimo, posizione, pulito, colazione, gentile, personale, camera, comodo,
bello, vicino
- Topic 1: centro, struttura, disponibile, servizio, hotel, buono, soggiorno,
piacevole, utile
[...]
```

Perché funziona: il ruolo contestualizza il dominio e migliora la qualità semantica delle etichette. Il vincolo di formato (dizionario Python) produce output incollabile direttamente nel codice senza post-processing.

12.3 Chain-of-Thought (CoT) — Selezione del modello di sentiment

Contesto: dopo la validazione empirica (sezione 9), necessità di scegliere tra Feel-IT e nlptown come modello principale della pipeline.

Tecnica: chain-of-thought — si chiede al modello di ragionare passo per passo prima di formulare una raccomandazione. Produce ragionamenti più articolati e meno soggetti a semplificazioni.

```
Devo scegliere il modello di sentiment analysis principale per un corpus di 15.509
recensioni di hotel in italiano e inglese (Booking.com, Cagliari e Olbia, 2025-2026).
```

```
Ho confrontato due modelli su un gold standard annotato manualmente (150 rec.):
```

```
Feel-IT (MilaNLPProc/feel-it-italian-sentiment):
```

```
Accuracy: 58.0% | Macro F1: 0.395
```

```
Classe negative: Precision 0.031, Recall 0.667, F1 0.060
```

```
Classe positive: Precision 0.988, Recall 0.578, F1 0.730
```

```
nlptown (bert-base-multilingual-uncased-sentiment, 1-2 stelle=neg, 3-5=pos):
```

```
Accuracy: 96.0% | Macro F1: 0.490
```

```
Classe negative: Precision 0.000, Recall 0.000, F1 0.000
```

```
Classe positive: Precision 0.980, Recall 0.980, F1 0.980
```

```
Ragiona passo per passo considerando:
```

1. Il dominio di training di ciascun modello vs il dominio target
2. Le implicazioni di recall=0 sulla classe negativa vs precision=0.031
3. L'affidabilità dei confronti relativi (finestre, città) con ciascun modello
4. Il fatto che il gold standard ha solo 3 esempi negativi su 150

```
Alla fine, indica quale modello sceglieresti e perché, in 3-4 righe
adatte a un report tecnico universitario.
```

Perché funziona: elencare i passi di ragionamento costringe il modello a considerare tutte le dimensioni del problema. Senza il CoT, tende a scegliere il modello con accuracy più alta (96%) senza approfondire il paradosso del class imbalance.

12.4 Few-Shot Prompting — Annotazione manuale del gold standard

Contesto: costruzione del gold standard (sezione 9.1). Necessità di definire un criterio di etichettatura consistente per le 150 recensioni da annotare manualmente.

Tecnica: few-shot — fornire 3-5 esempi etichettati prima della richiesta. Particolarmente efficace per task di classificazione dove la definizione della categoria è sfumata (es. distinguere una recensione negativa da una mista).

Devo etichettare recensioni di hotel come 'positive' o 'negative' per costruire un gold standard per la validazione di modelli NLP. Segui questi esempi:

ESEMPI:

Testo positivo: "Ottima posizione nel centro storico, personale gentilissimo. Colazione abbondante. Camera pulita e confortevole."

Testo negativo: ""

Rating: 9/10 → Etichetta: positive

Motivazione: rating alto, testo privo di critiche reali.

Testo positivo: ""

Testo negativo: "Camera minuscola e buia, bagno fatiscante, rumore dalla strada tutta la notte. Non torneremo."

Rating: 4/10 → Etichetta: negative

Motivazione: rating basso, testo negativo dominante ed esplicito.

Testo positivo: "Posizione comoda vicino al porto. Personale cortese."

Testo negativo: "La stanza era piccola. Mancava il parcheggio."

Rating: 7/10 → Etichetta: positive

Motivazione: rating medio-alto, le critiche sono minori e non invalidano l'esperienza.

Ora etichetta le seguenti recensioni applicando lo stesso criterio.

Per ogni recensione indica: etichetta e motivazione breve (max 10 parole).

[lista recensioni da etichettare]

Perché funziona: i tre esempi coprono i casi prototipici (positivo, negativo, borderline). La richiesta di motivazione breve rende il ragionamento verificabile e consistente tra le annotazioni.

12.5 Role + CoT + Output Formatting — Interpretazione della divergenza Cagliari/Olbia

Contesto: sezione 7.2 del report. I dati mostrano una divergenza netta durante l'America's Cup (+0.895 Olbia vs +0.563 Cagliari). Necessità di interpretare il pattern in modo rigoroso.

Tecnica: combinazione di role prompting, chain-of-thought e output formatting. La combinazione è utile quando il task richiede expertise di dominio, rigore argomentativo e un formato specifico per l'inserimento nel report.

Sei un ricercatore di economia del turismo che sta scrivendo un paper sull'impatto di grandi eventi sportivi sulla qualità percepita delle strutture ricettive.

Analizza i seguenti dati di sentiment estratti da recensioni Booking.com (2026):

Cagliari (città ospitante America's Cup):

Pre-evento (1 apr - 20 mag): sentiment medio +0.702, rating medio 9.20

Durante (21-24 mag): sentiment medio +0.563, rating medio 8.65

Post-evento (25 mag - 15 giu): sentiment medio +0.736, rating medio 9.16

Olbia (città di controllo, stessa regione, nessun evento):

Pre-evento: sentiment medio +0.683, rating medio 8.84

Durante: sentiment medio +0.895, rating medio 9.64
Post-evento: sentiment medio +0.477, rating medio 8.70

Ragiona passo per passo su:

1. Cosa spiega la divergenza tra Cagliari e Olbia durante l'evento
2. Perché Olbia registra il suo valore massimo proprio durante l'America's Cup
3. Cosa indica il calo post-evento di Olbia rispetto alla ripresa di Cagliari
4. Come leggere i risultati alla luce del bias di nlptown verso la classe positiva

Output richiesto: 3 bullet point in italiano (massimo 2 righe ciascuno),
tono accademico, adatti a essere inseriti direttamente in un report universitario.

Perché funziona: la combinazione è la più potente per task interpretativi complessi. Il ruolo garantisce il registro accademico; il CoT evita interpretazioni superficiali; il vincolo di formato rende l'output immediatamente utilizzabile nel report.

Nota metodologica sull'uso degli LLM nel progetto

L'utilizzo di LLM come assistenti di sviluppo ha accelerato fasi operative (scrittura di codice, reformatting di output, verifica di consistenza interna dei risultati) e ha supportato la fase interpretativa fornendo un secondo punto di vista argomentato.

Tutti i risultati quantitativi del report provengono esclusivamente dall'esecuzione della pipeline Python (analysis/): i modelli NLP usati per il sentiment e il topic modeling sono nlptown, Feel-IT e BERTopic, non LLM generativi. Gli LLM sono stati usati come strumento di lavoro, non come componente analitica.